

Ingeniería del Conocimiento

Machine Learning

Jaime Huaytalla Pariona


Sesión 2

jhuaytalla@uncp.edu.pe

Agenda

- Metodología de Proyectos de ML
- CRISP-DM for Machine Learning Projects


Vector de Características




- Un vector de observaciones(medidas).
- Es un punto en el espacio

¿Que es una característica?

- Característica
 - Una característica es cualquier aspecto distintivo, calidad o característica.
 - Las características pueden ser simbólicas (color) o numéricas (altura).
- Definiciones
 - La combinación de características es representada como un vector de columna de "d" dimensiones llamada vector de características.
 - El espacio d dimensional definida por el vector es llamado espacio de características.
 - Los objetos son representados como puntos en el espacio de características. El grafico es llamado gráfico de dispersión.



Espacio de Características




"Good" features



"Bad" features


More feature properties




Linear separability



Non-linear separability



Highly correlated features




Multi-modal

“Buena” característica

- La calidad de un vector de características está relacionada con su capacidad para discriminar ejemplos de diferentes clases.
- Los ejemplos de la misma clase deben tener valores de características similares
- Los ejemplos de diferentes clases tienen diferentes valores de característica

Un Ejemplo

- “Clasificación de pescado entrante en una cinta transportadora según la especie mediante detección óptica”



Análisis del Problema


- Configure una cámara y tome algunas imágenes de muestra para extraer características
 - Longitud
 - Luminucidad
 - Ancho
 - Número y forma de las aletas.
 - Posición de la boca, etc...
- ¡Este es el conjunto de todas las características sugeridas para explorar y usar en nuestro clasificador!

Pre- procesamiento

Use una operación de segmentación para aislar peces entre sí y del fondo


La información de un solo pez se envía a un extractor de características cuyo propósito es reducir los datos midiendo ciertas características.

Las características se pasan a un clasificador (targeting)




Clasificación

- Seleccione la longitud del pez como posible característica para la discriminación




¡La longitud es una característica pobre sola!

Selecciona la luminosidad como posible característica.





- Límite de decisión de umbral y relación de costo
- Mueva nuestro límite de decisión hacia valores más ~~pequeños~~ de ligereza para minimizar el costo (¡reduzca la cantidad de lubinas que se clasifican como salmón!)




Teoria de decisión

- Adopta la luminicidad y añade el ancho del pez.






- Podríamos agregar otras características que no están correlacionadas con las que ya tenemos. Se debe tomar la precaución de no reducir el rendimiento agregando tales "características ruidosas"
- Idealmente, el mejor límite de decisión debería ser aquel que proporcione un rendimiento óptimo, como en la siguiente figura:



- Sin embargo, nuestra satisfacción es prematura porque el objetivo central de diseñar un clasificador es clasificar correctamente la entrada nueva.



Problema de generalización




Algunos trabajos de ML para Revisar

- [Aplicacion de Machine Learning para la prediccion de sismos en Lima e Ica – Troomes](#)
- [IA para predecir si un titular de una tarjeta de crédito pagará o no el saldo en mora del "pago mínimo facturado". – Troomes](#)
- [Implementación Sistema Predicción de Reclamos mediante el uso de machine Learning en una empresa de telecomunicaciones – Troomes](#)
- [Uso de Inteligencia Artificial para la identificación de zonas con mayor índice de tráfico de Animales Silvestres - Caso – Troomes](#)
- [Prediccion del Indice General de la Bolsa de Valores de Lima – Troomes](#)

Methodologies for Machine Learning Projects

- **CRISP-DM (Cross-Industry Standard Process for Data Mining):** CRISP-DM is one of the most widely adopted methodologies for data mining and machine learning projects.
- **TDSP (Team Data Science Process):** Developed by Microsoft, TDSP is a structured methodology designed to enable agile, iterative, and collaborative development of data science projects.
- **KDD (Knowledge Discovery in Databases):** KDD is a process of discovering useful knowledge from a collection of data.
- **Agile Methodologies:** Agile methodologies, like Scrum and Kanban, can also be applied to ML projects. These methodologies emphasize iterative development, collaboration, and flexibility.
- **DevOps for Machine Learning (MLOps):** MLOps is a set of practices that combines machine learning, DevOps, and data engineering to deploy and maintain ML models in production reliably and efficiently.


CRISP-DM for Machine Learning Projects



1. Business understanding: Que necesita el negocio?
2. Data understanding: Que datos necesitamos/Tenemos? Estan limpios?
3. Data preparation: Como organizamos la Data para el modelamiento?
4. Modeling: Que técnicas de modelado deberíamos de aplicar?
5. Evaluation: Que modelos alcanzan los objetivos del negocio?
6. Deployment: Como los stakeholders acceden a los resultados?
7. Model Management: Validar el desempeño del modelo, monitorear datos de entrada, interpretar resultados

CRISP-DM para Proyectos de Machine Learning

Tareas Generales Para el Modelo Mejorado en CRISP-DM



Proceso en Proyectos de Datos/ML

1. **Comprensión del negocio:** asegurarse de que todas las partes interesadas entiendan el qué, cómo y por qué del proyecto.
2. **Comprensión de datos:** el objetivo es obtener una comprensión profunda de los datos.
3. **Preparación de datos:** incluye la transformación de los datos de un formulario sin procesar en datos que se pueden usar directamente en sus modelos
4. **Modelado de datos:** es ahora cuando intenta obtener los conocimientos o hacer las predicciones establecidas en el estatuto de su proyecto.
5. **Evaluación:** presentación de sus resultados y automatización del análisis.
6. **Despliegue:** Plan de Despliegue, Monitoreo y Mantenimiento.

Paso 1: Comprensión del Negocio

- Un proyecto comienza por comprender el **qué**, el **por qué** y el **cómo** de su proyecto.
- ¿**Qué** espera la empresa que usted haga? ¿Y por qué la gerencia le da tanto valor a su investigación?. ¿Es parte de un panorama estratégico mayor o un proyecto que surge de una oportunidad que alguien detectó?
- **El resultado:** un objetivo de investigación claro, una buena comprensión del contexto, entregables bien definidos y un plan de acción con un cronograma.

Paso 1: Comprensión del Negocio


- **Dedique tiempo a comprender los objetivos y el contexto de su investigación:**
 - El resultado es el objetivo de la investigación que establece el propósito de su tarea de manera clara y enfocada. Comprender los objetivos comerciales y el contexto es fundamental para el éxito del proyecto.
- **Crear una carta de proyecto:**
 - Un claro objetivo de investigación.
 - La misión y el contexto del proyecto
 - Cómo vas a realizar tu análisis
 - Qué recursos espera utilizar
 - Prueba de que es un proyecto realizable, o prueba de conceptos
 - Entregables y una medida del éxito
 - Una línea de tiempo

Paso 2: Comprensión del Dato

- El siguiente paso en la ciencia de datos es recuperar los datos requeridos.
- A veces necesita ir al campo y diseñar un proceso de recopilación de datos usted mismo, pero la mayoría de las veces no estará involucrado en este paso. Muchas empresas ya habrán recopilado y almacenado los datos por usted, y lo que no tienen a menudo se puede comprar a terceros.
- Los datos se pueden almacenar de muchas formas, desde simples archivos de texto hasta tablas en una base de datos.
- Realice verificaciones de calidad de datos ahora para evitar problemas más adelante

Step 2: Compresión del Dato




A Data Lake Architecture



Database, Data Marts, Data Warehouses, Data Lakes.


Análisis Exploratorio de Datos

- Durante el análisis exploratorio de datos, se sumerge profundamente en los datos. La información se vuelve mucho más fácil de captar cuando se muestra en una imagen, por lo tanto, utiliza principalmente técnicas gráficas para comprender sus datos y las interacciones entre las variables.
- Las técnicas de visualización que utiliza en esta fase van desde simples gráficos de líneas o histogramas hasta diagramas más complejos como Sankey y gráficos de red.




Análisis Exploratorio de Datos

- Estructura de los datos sobre otras variables





- Un diagrama de Pareto es una combinación de los valores y una distribución acumulativa.



Análisis Exploratorio de Datos

- Diagrama de caja. Los diagramas de caja son una forma estandarizada de mostrar la distribución de datos basada en un resumen de cinco números ("mínimo", primer cuartil (Q1), mediana, tercer cuartil (Q3) y "máximo").
- https://matplotlib.org/3.1.3/gallery/pyplots/boxplot_demo_pyplot.html#sphx-glr-gallery-pyplots-boxplot-demo-pyplot-py



Paso 3: Preparación de Datos

- Limpieza de datos: la limpieza de datos se centra en eliminar errores en sus datos para que estos se conviertan en una representación fiel y coherente de los procesos de los que se originan.
 - Error de interpretación: la edad de esa persona es ≥ 300 años
 - Inconsistencias entre fuentes de datos: “Mujer” en una tabla y “F” en otra.


Limpieza de datos

General solution	
Try to fix the problem early in the data acquisition chain or else fix it in the program.	
Error description	Possible solution
<i>Errors pointing to false values within one data set</i>	
Mistakes during data entry	Manual overrules
Redundant white space	Use string functions
Impossible values	Manual overrules
Missing values	Remove observation or value
Outliers	Validate and, if erroneous, treat as missing value (remove or insert)
<i>Errors pointing to inconsistencies between data sets</i>	
Deviations from a code book	Match on keys or else use manual overrules
Different units of measurement	Recalculate
Different levels of aggregation	Bring to same level of measurement by aggregation or extrapolation

Limpieza de datos

- Errores de entrada de datos: la recopilación y la entrada de datos son procesos propensos a errores.
- Con una tabla de frecuencias se pueden detectar outliers.

Value	Count
Good	1598647
Bad	1354468
Godo	15
Bade	1



Limpieza de Datos

- Los espacios en blanco redundantes tienden a ser difíciles de detectar pero causan errores como lo harían otros caracteres redundantes. Desajuste de claves como “Lima” con “Lima”. En python, elimine espacios con strip().
- La corrección de los desajustes de letras mayúsculas es común. En python puedes comparar: “Lima”.lower() == “lima”.lower()
- Valores imposibles y comprobaciones de cordura: aquí se comprueba el valor frente a valores física o teóricamente imposibles, como personas que midan más de 3 metros o alguien con una edad de 299 años.

Limpieza de Datos

- Outliers: Un valor atípico es una observación que parece estar distante de otras observaciones o, más específicamente, una observación que sigue una lógica diferente o un proceso generativo que las otras observaciones. La forma más fácil de encontrar valores atípicos es usar una gráfica o una tabla con los valores mínimos y máximos.



Limpieza de Datos

- Tratar con valores faltantes podría ser un indicador de que algo salió mal en su recopilación de datos o que ocurrió un error en el proceso ETL.

Technique	Advantage	Disadvantage
Omit the values	Easy to perform	You lose the information from an observation
Set value to null	Easy to perform	Not every modeling technique and/or implementation can handle null values
Impute a static value such as 0 or the mean	Easy to perform You don't lose information from the other variables in the observation	Can lead to false estimations from a model
Impute a value from an estimated or theoretical distribution	Does not disturb the model as much	Harder to execute You make data assumptions
Modeling the value (nondependent)	Does not disturb the model too much	Can lead to too much confidence in the model Can artificially raise dependence among the variables Harder to execute You make data assumptions

Limpieza de Datos


- Desviaciones de un libro de códigos: la detección de errores en conjuntos de datos más grandes en comparación con un libro de códigos o con valores estandarizados se puede realizar con la ayuda de operaciones de conjunto.
- Diferentes unidades de medida: al integrar dos conjuntos de datos, debe prestar atención a sus respectivas unidades de medida.
- Diferentes niveles de agregación: tener diferentes niveles de agregación es similar a tener diferentes tipos de medición. Ejemplo: Datos por semana vs Datos por mes.

Integración de Datos

- Sus datos provienen de varios lugares diferentes, y en este subpaso nos enfocamos en integrar estas diferentes fuentes. Los datos varían en tamaño, tipo y estructura, desde bases de datos y archivos de Excel hasta documentos de texto.
- Dos operaciones para combinar datos: unir y agregar (o apilar).


Integración de Datos

- Unión de tablas: enriquecer una observación de una tabla con información de otra tabla:
 - `SELECT table1.field2, table2.field3.... FROM table1 INNER JOIN table 2 ON table1.field1 = table2. field1;`



Integración de Datos

- Agregar tablas: Agregar o apilar tablas es efectivamente agregar observaciones de una tabla a otra tabla.
 - `SELECT * FROM table1 UNION SELECT * FROM table2;`



Integración de Datos


- Enriquecimiento de medidas agregadas: el enriquecimiento de datos también se puede realizar agregando información calculada a la tabla, como el número total de ventas o qué porcentaje del stock total se ha vendido en una determinada región.

Product class	Product	Sales in \$	Sales t-1 in \$	Growth	Sales by product class	Rank sales
A	B	X	Y	$(X-Y) / Y$	AX	NX
Sport	Sport 1	95	98	-3.06%	215	2
Sport	Sport 2	120	132	-9.09%	215	1
Shoes	Shoes 1	10	6	66.67%	10	3

Transformación de Datos

- Transformación de datos: Ciertos modelos requieren que sus datos tengan una determinada forma. Transformar sus datos para que adopten una forma adecuada para el modelado de datos.
- $Y = a e^{bx}$


x	1	2	3	4	5	6	7	8	9	10
log(x)	0.00	0.43	0.68	0.86	1.00	1.11	1.21	1.29	1.37	1.43
y	0.00	0.44	0.69	0.87	1.02	1.11	1.24	1.32	1.38	1.46



Transformación de Datos

- Reducción del número de variables: a veces tiene demasiadas variables y necesita reducir el número porque no agregan información nueva al modelo. Utilizando el modelo PCA.
- Convertir variables en ficticias: las variables se pueden convertir en variables ficticias. Las variables ficticias solo pueden tomar dos valores: verdadero (1) o falso (0)..

Customer	Year	Gender	Sales
1	2015	F	10
2	2015	M	8
1	2016	F	11
3	2016	M	12



Customer	Year	Sales	Male	Female
1	2015	10	0	1
1	2016	11	0	1
2	2015	8	1	0
3	2016	12	1	0

Paso 5: Construcción de Modelos

- Con datos limpios en su lugar y una buena comprensión del contenido, está listo para crear modelos con el objetivo de hacer mejores predicciones, clasificar objetos o comprender el sistema que está modelando.

Estrategia para Entrenar Modelos

- Entrenamiento y Prueba el algoritmo (Supervisado)
 - Entrene los modelos con el 80% de los datos
 - Pruebe los modelos con el 20% de los datos
 - Seleccione el algoritmo con mejores resultados (es decir,% de instancias clasificadas correctamente, matriz de confusión y otros)
- En caso de Aprendizaje No Supervisado, utilice otras métricas para evaluar el éxito (Error Cuadrático Medio).
 - Refina el algoritmo
 - Refine el algoritmo (es decir, cambie algunos parámetros, cambie algunas variables de entrada, otras)
 - Pase a producción y controle los resultados.
 - Vuelva a entrenar en caso de ser necesario.

Entrenamiento del Modelo

- Ejecutar un modelo de predicción lineal en datos semi-aleatorios


```
import statsmodels.api as sm
import numpy as np
predictors = np.random.random(1000).reshape(500,2)
target = predictors.dot(np.array([0.4, 0.6])) + np.random.random(500)
lmRegModel = sm.OLS(target,predictors)
result = lmRegModel.fit()
result.summary()
```

Shows model
fit statistics.

Fits linear
regression
on data.

Imports required
Python modules.

Creates random data for
predictors (x-values) and
semi-random data for
the target (y-values) of the
model. We use predictors as
input to create the target so
we infer a correlation here.



Ejecución del Modelo

Dep. Variable:	y	R-squared:	0.893
Model:	OLS	Adj. R-squared:	0.893
Method:	Least Squares	F-statistic:	2098.
Date:	Fri. 30 Oct 2015	Prob (F-statistic):	7.13e-243
Time:	12:44:31	Log-Likelihood:	-178.74
No. Observations:	500	AIC:	357.5
Df Residuals:	498	BIC:	385.9
Df Model:	2		
Covariance Type:	nonrobust		

Model fit: higher is better but too high is suspicious.

The Formula for R-Squared Is

$$R^2 = 1 - \frac{\text{Unexplained Variation}}{\text{Total Variation}}$$

p-value to show whether a predictor variable has a significant influence on the target. Lower is better and <0.05 is often considered "significant."

	coef	std err	t	P> t	[05.0% Conf. Int.]
x1	0.7658	0.040	19.130	0.000	0.687 0.844
x2	1.1252	0.039	28.603	0.000	1.048 1.202

Omnibus:	34.268	Durbin-Watson:	1.943
Prob(Omnibus):	0.000	Jarque-Bera (JB):	13.480
Skew:	-0.125	Prob(JB):	0.00118
Kurtosis:	2.235	Cond. No.	2.51

Linear equation coefficients.
 $y = 0.7658x_1 + 1.1252x_2$.

Figure 2.23 Linear regression model Information output

DATASETS

- Data Sets:
 - <https://www.datosabiertos.gob.pe>
 - Troomes: <https://www.troomes.com/viewforum.php?f=39>
 - Kaggle: <https://www.kaggle.com/competitions>
 - Machine Learning Repository – UCI: <http://archive.ics.uci.edu/ml/>
 - https://en.wikipedia.org/wiki/List_of_datasets_for_machine_learning_research
 - <https://dataverse.harvard.edu/>

Proyecto Grupal

- Objetivo: Desarrollar un sistema que use los algoritmos presentados en clase para resolver problemas elegidos por cada grupo.
- Data que puedes utilizar en su Proyecto:
 - Repositorios disponibles en la web:
 - <https://www.datosabiertos.gob.pe/>
 - <https://www.kaggle.com/datasets>
 - <https://archive.ics.uci.edu/ml/index.php>
 - <https://www.troomes.com/viewforum.php?f=39>
 - Data generada por los estudiantes
 - Data de otros cursos o de alguna compañía

Lectures of the week

- **Keep your AI projects on track:**

- <https://hbr.org/2023/11/keep-your-ai-projects-on-track>

- **The Reason Many AI and Analytics Projects Fail—and How to Make Sure Yours Doesn't:**

<https://www.cio.com/article/419552/the-reason-many-ai-and-analytics-projects-fail-and-how-to-make-sure-yours-doesnt.html>