

Modelos de Clasificación

Msc, Jaime Huaytalla Pariona

Agenda

- Decision Trees
- Random Forest
- Weka
- Example of Decision Trees using Weka
- Classification and Regression Example

Aprendizaje Supervisado - Clasificación

Cuando usamos clasificación, el resultado es una etiqueta, clase o categoría. Es decir, el resultado de la técnica de machine learning que estemos usando será un valor categórico, dentro de un conjunto finito de posibles resultados (número de clases).

Aquí van algunos ejemplos de clasificación:

- ✓ Predecir por si una persona tiene o no tiene diabetes
- ✓ Clasificar si un cliente va a darse de baja un servicio de la compañía
- ✓ Predecir si un estudiante va a salir reprobado de un curso en la universidad
- ✓ Predecir que partido político va a ganar las próximas elecciones

Árboles de Decisión

El objetivo de cualquier árbol de decisión es crear un modelo viable que prediga el valor de una variable objetivo en función del conjunto de variables de entrada.

Dos tipos principales:

- El análisis del árbol de clasificación es cuando el resultado predicho es la clase a la que pertenecen los datos.
- El análisis del árbol de regresión es cuando el resultado predicho puede considerarse un número real.

Se utiliza en muchas industrias: instituciones financieras, comercializadores, campo médico y otros

Ventaja: es fácil de leer. Desventaja: puede crear modelos complejos en función de los datos

Diferentes Tipos de Algoritmos

- C4.5: Se basa en el método de obtención de información. Permite que los árboles se utilicen para la clasificación. En Weka está el algoritmo J48.

Calcule el umbral para la división:


85,80,83,70,68,65,64,72,69,75,75,72,81,71

Dividir y dar un criterio de decisión simple: $a \leq 80$ o $a > 80$

Los árboles se podan

- CART (Classification and Regression Trees)
- ID3 (dicotomizador iterativo 3)
- CHAID (Detección automática de interacción chi-cuadrado)
- MARS (splines de regresión adaptativa multivariante)
- Gradient Boosted Trees (XGBoost, LightGBM, CatBoost)


Como los Arboles de Decisión Trabajan



- Los árboles se componen de nodos y bordes
- Cada nodo está asociado con una variable de entrada
- La raíz es el valor total posible de ese nodo
- Una hoja representa un valor basado en los valores dados por la variable de entrada.

¿Cuál es el mejor nodo para iniciar el árbol?


Arbol de Decisión para Regresión



Entropía

Cálculo de entropía (medida de incertidumbre).
Tiene un valor [0,1]

$$\text{Entropy} = \sum_i -p_i \log_2 p_i$$



p_i es la probabilidad de la clase i . Calcúlelo como la proporción de la clase i en el conjunto.

16/30 son círculos verdes; 14/30 son cruces rosas. $\log_2 (16/30) = -0,9$; $\log_2 (14/30) = -1,1$
Entropía = $-(16/30)(-0,9) - (14/30)(-1,1) = 0,99$

Entropía = 0: no es bueno para el conjunto de entrenamiento

Entropía = 1: bueno para el conjunto de entrenamiento

Building a Decision Tree: Example

Day	Outlook	Temperature	Humidity	Wind	Play Tennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

Building a Decision Tree: Example

$$Entropy(S) = -(P_{\oplus} \log_2 P_{\oplus} + P_{\ominus} \log_2 P_{\ominus}) \quad (1.1)$$

Where $P_{\oplus}$ is the portion of positive examples and $P_{\ominus}$ is the portion of negative examples in S .

$$Entropy([9+, 5-]) = -(\frac{9}{14} \log_2 \frac{9}{14} + \frac{5}{14} \log_2 \frac{5}{14}) = 0.940 \quad (1.2)$$

Which concludes, the dataset is 94% impure or 94% non-homogeneous.

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v) \quad (1.5)$$

Where, $Values(A)$ is the all possible values for attribute A , and S_v is the subset of S for which attribute A has value v .

Values(Wind) = Weak, Strong

$$S = [9+, 5-]$$

$$S_{\text{weak}} = [6+, 2-]$$

$$S_{\text{strong}} = [3+, 3-]$$

$$\text{Entropy}(S) = 0.940 \text{ from eqtn 1.2}$$

$$\text{Gain}(S, A) = \text{Entropy}(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \text{Entropy}(S_v)$$

$$\text{Gain}(S, \text{Wind}) = \text{Entropy}(S) - \left(\frac{8}{14} \text{Entropy}(S_{\text{weak}}) + \frac{6}{14} \text{Entropy}(S_{\text{strong}}) \right) \quad (1.6)$$

$$\text{Entropy}(S_{\text{weak}}) = -\left(\frac{6}{8} \log_2 \frac{6}{8} + \frac{2}{8} \log_2 \frac{2}{8} \right) = 0.811 \quad (1.7)$$

$$\text{Entropy}(S_{\text{strong}}) = -\left(\frac{3}{3} \log_2 \frac{3}{3} + \frac{3}{3} \log_2 \frac{3}{3} \right) = 1.00 \quad (1.8)$$

Put the values of $\text{Entropy}(S_{\text{weak}})$ and $\text{Entropy}(S_{\text{strong}})$ in eqtn 1.6

$$\begin{aligned} \text{Gain}(S, \text{Wind}) &= \text{Entropy}(S) - \left(\frac{8}{14} 0.811 + \frac{6}{14} 1.00 \right) \\ &= 0.940 - (0.463 + 0.429) \\ &= 0.048 \end{aligned} \quad (1.9)$$

$Values(Outlook) = Sunny, Overcast, Rain$

$S = [9+, 5-]$

$S_{sunny} = [2+, 3-]$

$S_{overcast} = [4+, 0-]$

$S_{rain} = [3+, 2-]$

$$G(S, Outlook) = Entropy(S) - \left(\frac{5}{14} Entropy(S_{sunny}) + \frac{4}{14} Entropy(S_{overcast}) + \frac{5}{14} Entropy(S_{rain}) \right) \quad (1.10)$$

$$Entropy(S_{sunny}) = -\left(\frac{2}{5} \log_2 \frac{2}{5} + \frac{3}{5} \log_2 \frac{3}{5} \right) = 0.971 \quad (1.11)$$


$$Entropy(S_{overcast}) = -\left(\frac{4}{4} \log_2 \frac{4}{4} + \frac{0}{4} \log_2 \frac{0}{4} \right) = 0 \quad (1.12)$$

$$Entropy(S_{rain}) = -\left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5} \right) = 0.971 \quad (1.13)$$

Put the values of eqtn 1.11, 1.12, 1.13 in 1.10.

$$G(S, Outlook) = 0.940 - \left(\frac{5}{14} 0.971 + \frac{4}{14} 0 + \frac{5}{14} 0.971 \right) = 0.246 \quad (1.14)$$


$Gain(S, Outlook) = 0.246$
 $Gain(S, Humidity) = 0.151$
 $Gain(S, Wind) = 0.048$
 $Gain(S, Temperature) = 0.029$



Which attribute should be tested here?


Random Forest

- Bosques aleatorios (Random forests) es un método de aprendizaje por conjuntos (ensemble learning) para clasificación, regresión y otras tareas, que funciona construyendo una multitud de árboles de decisión durante el entrenamiento y arrojando como resultado la clase que representa la moda de las clases (en clasificación) o la predicción media (en regresión) de los árboles individuales..



Random Forest

El algoritmo de entrenamiento para bosques aleatorios (random forests) aplica la técnica general de agregación por remuestreo con reemplazo (bootstrap aggregating o bagging) a los aprendices basados en árboles (tree learners).



Random Forest

Dado un conjunto de entrenamiento $X = x_1, \dots, x_n$ con respuestas $Y = y_1, \dots, y_n$, el *bagging* selecciona repetidamente (B veces) una muestra aleatoria con reemplazo del conjunto de entrenamiento y ajusta árboles a estas muestras:

Para $b = 1, \dots, B$:

Extraer una muestra, con reemplazo, de n ejemplos de entrenamiento de X, Y ; denominar a estos X_b, Y_b .

Entrenar un árbol de clasificación o regresión f_b sobre X_b, Y_b .

Después del entrenamiento, las predicciones para muestras no observadas x' se pueden realizar promediando las predicciones de todos los árboles de regresión individuales sobre x' :

$$\hat{f} = \frac{1}{B} \sum_{b=1}^B f_b(x')$$

o tomando el voto mayoritario en el caso de los árboles de clasificación.

Evaluación de Modelos

- Matriz de Confusión
- **Exactitud (Accuracy)**: Es el valor obtenido cuando dividimos el número total de predicciones correctas que hizo el modelo entre el número total de predicciones hechas por el modelo, incluyendo las incorrectas.
- **Precisión (Precision)**: La capacidad de un modelo de clasificación para devolver solo los puntos de datos de una clase.
- **Sensibilidad (Recall)**: La capacidad de un modelo de clasificación para identificar todos los puntos de datos en una clase relevante.
- **Puntuación F1 (F1-score)**: Una métrica única que combina la sensibilidad y la precisión utilizando la media armónica.
- **ROC**: La puntuación AUC del ROC nos indica cuán eficiente es el modelo. Cuanto mayor sea el AUC, mejor será el rendimiento del modelo para distinguir entre las clases positivas y negativas. Una puntuación AUC de 1 significa que el clasificador puede distinguir perfectamente entre todos los puntos de la clase Positiva y la clase Negativa.

Performance Evaluation

- Feature vectors are used as input for the classifier
- Classification results in a discrete class index
- Confusion matrix:

		hypothesis					
reference		Ω_1	Ω_2	Ω_3	...	Ω_K	Σ
	Ω_1	n_{11}	n_{12}	n_{13}	...	n_{1K}	N_1
	Ω_2	n_{21}	n_{22}	n_{23}	...	n_{2K}	N_2
	Ω_3	n_{31}	n_{32}	n_{33}	...	n_{3K}	N_3
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
	Ω_K	n_{K1}	n_{K2}	n_{K3}	...	n_{KK}	N_K
Σ							N

Tab.: Confusion matrix with absolute frequencies for a K -class problem

Performance Evaluation

Evaluation of classifiers

- Accuracy / Recognition Rate

$$\text{RR} := \frac{1}{N} \sum_{k=1}^K n_{kk} \cdot 100\%$$

- Recall and Precision

$$\begin{aligned} \text{recall}_k &= \frac{n_{kk}}{\sum_{i=1}^K n_{ki}} = \frac{n_{kk}}{N_k} \\ \text{precision}_k &= \frac{n_{kk}}{\sum_{i=1}^K n_{ik}} \end{aligned}$$

- (Unweighted) Average Recall

$$\text{UAR} := \frac{1}{K} \sum_{k=1}^K \frac{n_{kk}}{N_k} \cdot 100\%$$

Performance Evaluation




Weka

- Weka is a collection of machine learning algorithms for data mining tasks.
- Weka contains tools for data pre-processing, classification, regression, clustering, association rules, and visualization.
- You can create your own algorithms
- Course of Data Mining with Weka : <https://waikato.github.io/weka-wiki/documentation/>
- Go to: https://waikato.github.io/weka-wiki/downloading_weka/

Weka

- Install Weka
 - <http://www.cs.waikato.ac.nz/ml/weka/downloading.html>



Weka

- **Menus:**

- **Preprocess:** visualización y pre-procesado de los datos (aplicación de filtros)
- **Classify:** Aplicación de algoritmos de clasificación y regresión
- **Cluster:** Agrupación
- **Associate:** Asociación
- **Select Attributes:** Selección de atributos
- **Visualize:** Visualización de los datos por parejas de atributos

Weka File

- Different kind of input file: *.arff, *.csv


```
@relation ladygaga

@attribute placement {end_rack, cd_spec, std_rack}
@attribute prominence numeric
@attribute pricing numeric
@attribute eye_level {TRUE, FALSE}
@attribute customer_purchase {yes, no}

@data
end_rack,85,85,FALSE,yes
end_rack,80,90,TRUE,yes
cd_spec,83,86,FALSE,no
std_rack,70,96,FALSE,no
std_rack,68,80,FALSE,no
std_rack,65,70,TRUE,yes
cd_spec,64,65,TRUE,yes
end_rack,72,95,FALSE,yes
end_rack,69,70,FALSE,no
std_rack,75,80,FALSE,no
end_rack,75,70,TRUE,no
cd_spec,72,90,TRUE,no
cd_spec,81,75,FALSE,yes
std_rack,71,91,TRUE,yes
```


Preprocess the file

- Choose the file: edit it, save it.




How the attribute is classifying?

- ViewAll option




- Apply some filters or remove some attributes

- Apply some filters or remove some attributes




Classify



Classifier Parameters

- Select the parameters according to Classifier and precision



confidenceFactor -- The confidence factor used for pruning (smaller values incur more pruning).

The smaller the confidence factor the more pruning the algorithm will do

Pruning is a way of reducing the size of the decision tree

if you increase pruning, the accuracy on the training set will be lower

Choose Classifier: J48

- Choose the Classifier: for this session J48

The screenshot shows the WEKA Explorer window with the following components:

- Classifier:** A red box labeled "Clasificador de clase mayoritaria" points to the "ZeroR" button in the "Choose" dropdown.
- Test options:** The "Cross-validation" radio button is selected, with "Folds: 10" also circled in red.
- Start button:** The "Start" button is circled in red.
- Classifier output:**
 - A red box labeled "Porcentaje de aciertos en test" points to the "33.3333 %" value for "Correctly Classified Instances".
 - A red box labeled "Porcentaje de aciertos desglosados por clase" points to the "TP Rate" column in the "Detailed Accuracy By Class" table.
 - A red box labeled "Matriz de confusión" points to the "Confusion Matrix" section.

Classifier output details:

Time taken to build model: 0 seconds

--- Stratified cross-validation ---

--- Summary ---

Correctly Classified Instances	50	33.3333 %
Incorrectly Classified Instances	100	66.6667 %
Kappa statistic	0	
Mean absolute error	0.4444	
Root mean squared error	0.4714	
Relative absolute error	100 %	
Root relative squared error	100 %	
Total Number of Instances	150	

--- Detailed Accuracy By Class ---

	TP Rate	FP Rate	Precision	Recall	F-Measure	ROC Area	Class
	1	1					Iris-setosa
	0	0					Iris-versicolor
	0	0					Iris-virginica
Weighted Avg.	0.333	0.333	0.111	0.333	0.167	0.5	

--- Confusion Matrix ---

a	b	c	<-- classified as
50	0	0	a = Iris-setosa
50	0	0	b = Iris-versicolor
50	0	0	c = Iris-virginica

Choose Classifier: J48

- Choose the Classifier: for this session J48

The screenshot shows the Weka Explorer interface with the 'Classify' tab selected. The 'Classifier' section shows 'J48 -C 0.25 -M 2' selected. In the 'Test options' section, 'Cross-validation' is selected with 'Folds' set to 10. The 'Start' button is also visible. The 'Classifier output' section displays the results of the stratified cross-validation.

Classifier output

Time taken to build model: 0.17 seconds

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances	3145	94.3594 %
Incorrectly Classified Instances	188	5.6406 %
Kappa statistic	0.7524	
Mean absolute error	0.083	
Root mean squared error	0.2307	
Relative absolute error	33.4618 %	
Root relative squared error	65.5264 %	
Total Number of Instances	3333	

=== Detailed Accuracy By Class ===



	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.984	0.292	0.952	0.984	0.968	0.758	0.854	0.942	No
	0.708	0.016	0.879	0.708	0.784	0.758	0.854	0.730	Yes
Weighted Avg.	0.944	0.252	0.942	0.944	0.941	0.758	0.854	0.912	

=== Confusion Matrix ===

a	b	<-- classified as	
2803	47	a	= No
141	342	b	= Yes


Opciones de Prueba: Cross-Validation k Folds

1. Mezcle el conjunto de datos de forma aleatoria.
2. Divida el conjunto de datos en k grupos
3. Para cada grupo único:
 - a. Tome el grupo como un conjunto de datos de prueba o de reserva
 - b. Tome los grupos restantes como un conjunto de datos de entrenamiento
 - c. Coloque un modelo en el conjunto de entrenamiento y evalúelo en el conjunto de prueba
 - d. Conserve la puntuación de la evaluación y descarte el modelo
4. Resuma la habilidad del modelo usando la muestra de puntajes de evaluación del modelo.




Generación de Resultados de los Modelos Creados


1. Click en **More Options**




2. Seleccionar Choose, y doble click para seleccionar el tipo de archivo de salida



3. Selección el Tipo de Archivo. Por ejemplo: CSV




4. Ingresar el nombre del Archivo de Salida




Visualize the Tree

- The Tree pruned by J48



Visualize Attributes

- Attributes more relevant: Can classify the Classes



Java Code generated by Weka

The screenshot shows the Weka software interface with the 'Classify' tab selected. The 'Classifier' dropdown is set to 'J48 - C 0.95 - M 2'. Under 'Test options', 'Cross-validation' is selected with 10 folds. The 'Result list' on the left shows a series of runs, with the most recent one, '07:38:39 - trees.J48', highlighted. The 'Classifier output' pane on the right displays the generated Java code, which includes package declarations, imports, and a wrapper class for the J48 classifier.

Preprocess | **Classify** | Cluster | Associate | Select attributes | Visualize

Classifier
Choose **J48 - C 0.95 - M 2**

Test options
☐ Use training set
☐ Supplied test set Set...
☒ Cross-validation Folds **10**
☐ Percentage split % **66**
More options...

(Nom) class
Start Stop

Result list (right-click for options)

- 21:42:55 - trees.J48
- 21:43:59 - trees.J48
- 22:16:13 - trees.J48
- 22:18:44 - rules.PART
- 22:19:05 - bayes.BayesNet
- 22:19:34 - trees.J48
- 22:19:57 - trees.J48
- 22:20:20 - trees.J48
- 03:40:03 - trees.J48
- 03:57:36 - trees.J48
- 03:57:46 - trees.J48
- 03:58:53 - trees.J48
- 03:59:18 - trees.J48
- 04:03:22 - trees.J48
- 07:36:04 - trees.J48
- 07:37:25 - trees.J48
- 07:38:39 - trees.J48**

Classifier output

```
0 2 48 | c = Iris-virginica

=== Source code ===

// Generated with Weka 3.6.13
//
// This code is public domain and comes with no warranty.
//
// Timestamp: Sat Sep 26 07:38:41 COT 2015

package weka.classifiers;

import weka.core.Attribute;
import weka.core.Capabilities;
import weka.core.Capabilities.Capability;
import weka.core.Instance;
import weka.core.InstANCES;
import weka.core.RevisionUtils;
import weka.classifiers.Classifier;

public class WekaWrapper
    extends Classifier {

    /**
     * Returns only the toString() method.
     *
     * @return a string describing the classifier
     */
    public String globalInfo() {
        return toString();
    }
}
```

Testing Classifier Code

- Changing the last value with “?”

```
std_rack,70,96,FALSE,?  
std_rack,68,80,FALSE,?  
std_rack,65,70,TRUE,?  
cd_spec,64,65,TRUE,?  
end_rack,72,95,FALSE,?  
end_rack,69,70,FALSE,?  
std_rack,75,80,FALSE,?  
end_rack,75,70,TRUE,?  
cd_spec,72,90,TRUE,?  
cd_spec,81,75,FALSE,?  
std_rack,71,91,TRUE,?
```

- Copy the Java code created by Weeka and Execute it

```
0.0 -> yes  
0.0 -> yes  
1.0 -> no  
1.0 -> no  
1.0 -> no  
0.0 -> yes  
0.0 -> yes  
0.0 -> yes
```

Ejercicio: Comparar J48 y Random Forest

Archivo: debiates.arff

- **Número de embarazos**
- **Concentración de glucosa en plasma a 2 horas en una prueba de tolerancia a la glucosa oral**
- **Presión arterial diastólica (mm Hg):** Cuando su corazón está en reposo, entre latidos, su presión arterial baja
- **Espesor del pliegue cutáneo del tríceps (mm)**
- **Insulina sérica de 2 horas (mu U / ml):** Es una prueba que mide cuánta insulina tiene en la sangre.
- **Índice de masa corporal (peso en kg / (altura en m) ^ 2)**
- **Función pedigrí de la diabetes:** Una función que califica la probabilidad de diabetes según los antecedentes familiares.
- **Edad (años)**
- **Variable de clase (0 o 1):** El paciente muestra signos de diabetes (1), (0) en caso contrario.

Ejercicio: Comparar J48 y Random Forest

Weka Explorer

Preprocess Classify Cluster Associate Select attributes Visualize Auto-WEKA DI4j Inference

Classifier

Choose RandomForest -P 100 -I 100 -num-slots 1 -K 0 -M 1.0 -V 0.001 -S 1

Test options

☐ Use training set

☐ Supplied test set Set...

☒ Cross-validation Folds 10

☐ Percentage split % 66

More options...

(Nom) class

Start Stop

Result list (right-click for options)

- 18:46:11 - trees.J48
- 19:00:21 - trees.J48
- 19:11:58 - trees.J48
- 19:13:01 - trees.RandomForest

Classifier output

Time taken to build model: 0.01 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	567	73.8281 %
Incorrectly Classified Instances	201	26.1719 %
Kappa statistic	0.4164	
Mean absolute error	0.3158	
Root mean squared error	0.4463	
Relative absolute error	69.4841 %	
Root relative squared error	93.6293 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.814	0.403	0.790	0.814	0.802	0.417	0.751	0.811	tested_negative
	0.597	0.186	0.632	0.597	0.614	0.417	0.751	0.572	tested_positive
Weighted Avg.	0.738	0.327	0.735	0.738	0.736	0.417	0.751	0.727	

=== Confusion Matrix ===

a	b	<-- classified as
407	93	a = tested_negative
108	160	b = tested_positive

Ejercicio: Comparar J48 y Random Forest

Weka Explorer

Preprocess Classify Cluster Associate Select attributes Visualize Auto-WEKA DI4j Inference

Classifier

Choose RandomForest -P 100 -I 100 -num-slots 1 -K 0 -M 1.0 -V 0.001 -S 1

Test options

☐ Use training set
☐ Supplied test set Set...
☒ Cross-validation Folds 10
☐ Percentage split % 66

More options...

(Nom) class

Start Stop

Result list (right-click for options)

- 18:46:11 - trees.J48
- 19:00:21 - trees.J48
- 19:11:58 - trees.J48
- 19:13:01 - trees.RandomForest

Classifier output

```
weka.classifiers.trees.RandomTree -K 0 -M 1.0 -V 0.001 -S 1 -do-not-check-capabilities
```

Time taken to build model: 0.3 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	582	75.7813 %
Incorrectly Classified Instances	186	24.2188 %
Kappa statistic	0.4566	
Mean absolute error	0.3106	
Root mean squared error	0.4031	
Relative absolute error	68.3405 %	
Root relative squared error	84.5604 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
0.836	0.388	0.801	0.836	0.818	0.458	0.820	0.886	tested_negative
0.612	0.164	0.667	0.612	0.638	0.458	0.820	0.679	tested_positive
Weighted Avg.	0.758	0.310	0.754	0.758	0.755	0.458	0.814	

=== Confusion Matrix ===

a	b	<-- classified as
418	82	a = tested_negative
104	164	b = tested_positive

Classification Example

Exercise:

- Algorithm: J48 and Random Forest
- File: “Telco Churn dataset_procesado.csv”

Aprendizaje Supervisado - Regresión

Cuando usamos regresión, el resultado es un número. Es decir, el resultado de la técnica de machine learning que estemos usando será un valor numérico, dentro de un conjunto infinito de posibles resultados.

Aquí van algunos ejemplos de regresión:


- ✓ Predecir por cuánto se va a vender una propiedad inmobiliaria
- ✓ Predecir cuantos accidentes de transito tendremos la siguiente semana
- ✓ Estimar cuantos estudiantes tendrán un mal desempeño escolar el próximo trimestre
- ✓ Estimar cuantos vehículos se matricularan en los próximos meses
- ✓ Estimar cuanto se va a vender en proxima época navideña

Aprendizaje Supervisado - Regresión

Hay varias técnicas de machine learning que podemos usar en problemas de Regresión. Podemos destacar:

- ✓ Regresión lineal y regresión no lineal
- ✓ Máquinas de soporte vectorial (support vector machines)
- ✓ Árboles de decisión
- ✓ Random forests
- ✓ Redes neuronales y aprendizaje profundo (deep learning)

Regresión Lineal



Classifier

Choose **LinearRegression** -S 0 -R 1.0E-8 -num-decimal-places 4

Test options

- ☐ Use training set
- ☐ Supplied test set
- ☒ Cross-validation Folds
- ☐ Percentage split %

(Num) Y house price of unit area

Result list (right-click for options)

20:03:00 - functions.LinearRegression

Classifier output

```
X6 longitude
Y house price of unit area
Test mode: 10-fold cross-validation

=== Classifier model (full training set) ===

Linear Regression Model

Y house price of unit area =
-0.2687 * X2 house age +
-0.0042 * X3 distance to the nearest MRT station +
1.1648 * X4 number of convenience stores +
238.6357 * X5 latitude +
-5516.0065

Time taken to build model: 0 seconds

=== Cross-validation ===
=== Summary ===

Correlation coefficient      0.7483
Mean absolute error         6.2739
Root mean squared error     9.0163
Relative absolute error     58.3412 %
Root relative squared error 66.0214 %
Total Number of Instances   414
```

Modelo entrenado

Correlación entre la valor deseado y el valor real

Error cuadrático medio del modelo

Resultados:

- ✓ Coeficiente de correlación: 0.7483
- ✓ Error cuadrático medio: 9.0163

Algoritmo de Regresión

Choose REPTree -M 2 -V 0.001 -N 3 -S 1 -L -1 -I 0.0

Test options

☐ Use training set

☐ Supplied test set Set...

☒ Cross-validation Folds 10

☐ Percentage split % 66

More options...

(Num) Y house price of unit area

Start Stop

Classifier output

```
| X2 house age >= 11.2
| | X6 longitude < 121.54 : 38.89 (56/58.38) [30/44.18]
| | X6 longitude >= 121.54
| | | X3 distance to the nearest MRT station < 330.23 : 48.61 (30/77.31) [17/86.99]
| | | X3 distance to the nearest MRT station >= 330.23 : 39.32 (22/34.94) [18/34.91]
X3 distance to the nearest MRT station >= 763.37
| X5 latitude < 24.98
| | X3 distance to the nearest MRT station < 4007.27
| | | X2 house age < 17.75 : 27.12 (40/19.42) [19/12.81]
| | | X2 house age >= 17.75
| | | | X5 latitude < 24.95 : 17.26 (5/15.07) [3/18.18]
| | | | X5 latitude >= 24.95 : 24.79 (22/9.01) [6/24.7]
| | X3 distance to the nearest MRT station >= 4007.27 : 16.74 (18/10.65) [14/12.3]
| X5 latitude >= 24.98 : 36.81 (17/38.71) [10/122.69]
```

Size of the tree : 17

Time taken to build model: 0.01 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.7875
Mean absolute error	5.6204
Root mean squared error	8.438
Relative absolute error	52.2643 %
Root relative squared error	61.787 %
Total Number of Instances	414

20:35:48 - trees.REPTree

Mide la correlación entre los resultados deseados y los obtenidos (mayor valor es mejor)

Es el error cuadrático medio de los valores deseados con los valores reales (menor valor es mejor)

Regression Example

- Algorithm: REPTree
- File: “Real estate valuation data set.csv”

The screenshot displays the WEKA software interface, specifically the 'Classify' tab. The 'Classifier' dropdown is set to 'REPTree -M 2 -V 0.001 -N 3 -S 1 -L -1 -I 0.0'. Under 'Test options', 'Cross-validation' is selected with 'Folds' set to 10. The '(Num) Y house price of unit area' is selected for the result list. The 'Classifier output' pane shows the decision tree structure and performance metrics.

Classifier output

```
| | | | X1 transaction date >= 2013.46 : 44.91 (8/54.84) [2/52.61]
| | | | X6 longitude >= 121.54
| | | | X3 distance to the nearest MRT station < 330.23 : 48.61 (30/77.31) [17/86.99]
| | | | X3 distance to the nearest MRT station >= 330.23 : 39.32 (22/34.94) [18/34.91]
| | | | X3 distance to the nearest MRT station >= 763.37
| | | | X5 latitude < 24.98
| | | | X3 distance to the nearest MRT station < 4007.27
| | | | X2 house age < 17.75 : 27.12 (40/19.42) [19/12.81]
| | | | X2 house age >= 17.75
| | | | X5 latitude < 24.95 : 17.26 (5/15.07) [3/18.18]
| | | | X5 latitude >= 24.95 : 24.79 (22/9.01) [6/24.7]
| | | | X3 distance to the nearest MRT station >= 4007.27 : 16.74 (18/10.65) [14/12.3]
| | | | X5 latitude >= 24.98 : 36.81 (17/38.71) [10/122.69]
```

Size of the tree : 31

Time taken to build model: 0.04 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.7797
Mean absolute error	5.7935
Root mean squared error	8.607
Relative absolute error	53.8738 %
Root relative squared error	63.0238 %
Total Number of Instances	414

Status

OK Log x 0

Paper of week

- **Decision Tree:** <https://www.hackerearth.com/practice/machine-learning/machine-learning-algorithms/ml-decision-tree/tutorial/>
- **On Building Decision Trees from Large-scale Data in Applications of On-line Advertising**, Shivaram Kalyanakrishnan, Deepthi Singh, Ravi Kant.

References

- <https://hackernoon.com/a-brief-look-at-sklearn-tree-decisiontreeclassifier-c2ee262eab9a>
- **Machine Learning**, Hands-On for Developers and Technical Professionals, *Jason Bell*, Willey.
- **Machine Learning in Action**, *Peter Harrington*, Manning Shelter Island
- **Machine Learning Projects for .NET developers**, *Mathias Brandewinder*, Apress