

TRABAJO DE INGENIERIA DEL CONOCIMIENTO


Alumno: Briceño Carrión Polmar Yacid

Fecha: 24 / 09 / 26

El desarrollo de esta actividad lo haremos mediante pasos, empezando desde la carga de la dataset que en este caso será la “Diabetes”.

• PASO 1:

Abrimos WEKA para posteriormente hacemos click en “Explorer”, una vez abierto la siguiente pestaña le damos click a “Open File” y tendremos que buscar el dataset que ya viene por defecto con el programa de WEKA, teniendo como resultado la siguiente pestaña:



• PASO 2:

Podemos observar que tenemos 768 instancias, 9 atributos (preg, plas, pres, skin, insu, mass, pedi, age, class). Todos estos sin filtros aplicados.

Hacemos click en Classify → Choose → tres → J48, Después de estos pasos en Test Options, dejamos marcado Cross-validation con Folds: 10 y finalmente presionamos en Start.

Se observara las siguientes capturas del resultado después de dar en Start:

Classifier output

=== Run information ===

Scheme: weka.classifiers.trees.J48 -C 0.25 -M 2
Relation: pima_diabetes
Instances: 768
Attributes: 9
preg
plas
pres
skin
insu
mass
pedi
age
class
Test mode: 10-fold cross-validation

=== Classifier model (full training set) ===

J48 pruned tree

=== Classifier model (full training set) ===

J48 pruned tree

```
plas <= 127
| mass <= 26.4: tested_negative (132.0/3.0)
| mass > 26.4
| | age <= 28: tested_negative (180.0/22.0)
| | age > 28
| | | plas <= 99: tested_negative (55.0/10.0)
| | | plas > 99
| | | | pedi <= 0.56: tested_negative (84.0/34.0)
| | | | pedi > 0.56
| | | | | preg <= 6
| | | | | | age <= 30: tested_positive (4.0)
| | | | | | age > 30
| | | | | | age <= 34: tested_negative (7.0/1.0)
| | | | | | age > 34
| | | | | | mass <= 33.1: tested_positive (6.0)
| | | | | | mass > 33.1: tested_negative (4.0/1.0)
| | | | | | preg > 6: tested_positive (13.0)
plas > 127
```

```

|   mass <= 29.9
|   |   plas <= 145: tested_negative (41.0/6.0)
|   |   plas > 145
|   |   |   age <= 25: tested_negative (4.0)
|   |   |   age > 25
|   |   |   |   age <= 61
|   |   |   |   |   mass <= 27.1: tested_positive (12.0/1.0)
|   |   |   |   |   mass > 27.1
|   |   |   |   |   |   pres <= 82
|   |   |   |   |   |   |   pedi <= 0.396: tested_positive (8.0/1.0)
|   |   |   |   |   |   |   pedi > 0.396: tested_negative (3.0)
|   |   |   |   |   |   |   pres > 82: tested_negative (4.0)
|   |   |   |   |   |   age > 61: tested_negative (4.0)
|   mass > 29.9
|   |   plas <= 157
|   |   |   pres <= 61: tested_positive (15.0/1.0)
|   |   |   pres > 61
|   |   |   |   age <= 30: tested_negative (40.0/13.0)
|   |   |   |   age > 30: tested_positive (60.0/17.0)
|   |   plas > 157: tested_positive (92.0/12.0)

```

Number of Leaves : 20

Size of the tree : 39

Time taken to build model: 0.03 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	567	73.8281 %
Incorrectly Classified Instances	201	26.1719 %
Kappa statistic	0.4164	
Mean absolute error	0.3158	
Root mean squared error	0.4463	
Relative absolute error	69.4841 %	
Root relative squared error	93.6293 %	
Total Number of Instances	768	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.814	0.403	0.790	0.814	0.802	0.417	0.751	0.811	tested_negative
	0.597	0.186	0.632	0.597	0.614	0.417	0.751	0.572	tested_positive
Weighted Avg.	0.738	0.327	0.735	0.738	0.736	0.417	0.751	0.727	

=== Confusion Matrix ===

```


a  b  <-- classified as
407 93 | a = tested_negative
108 160 | b = tested_positive

```

Tenemos el siguiente resumen:

- Accuracy: 73.83% (567/768 correctas)
- Kappa: 0.4164 (concordancia moderada)

- Árbol: 39 nodos, 20 hojas
- Matriz de confusión: de los que realmente tenían diabetes (268 positivos), el modelo solo detectó 160 (recall 0.597) — se le escaparon 108 casos como falsos negativos. Ese es el punto débil que probablemente cambie después de tratar los outliers.
- **PASO 3:** Podemos Visualizar el árbol que generó el programa:




• **PASO 4:**

Para el filtrado de información primero tenemos que ver las variables:

El dataset tiene los siguientes atributos:

- **preg** → cantidad de embarazos
- **plas** → concentración de glucosa en plasma (test de tolerancia oral)
- **pres** → presión arterial diastólica
- **skin** → grosor del pliegue cutáneo del tríceps
- **insu** → insulina sérica a las 2 horas

- **mass** → índice de masa corporal (IMC)
- **pedi** → función de pedigrí de diabetes (antecedente genético/familiar)
- **age** → edad
- **class** → si dio positivo o negativo para diabetes



Podemos observar que casi 400 datos de la variable insulina están en 0, por lo que si los eliminamos nos quedaríamos sin datos.

- **PASO 5:**

Colocamos en el botón "Edit"

Viewer

Relation: pima_diabetes

No.	1: preg	2: plas	3: pres	4: skin	5: insu	6: mass	7: pedi	8: age	9: class
	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Nominal
1	6.0	148.0	72.0	35.0	0.0	33.6	0.627	50.0	tested...
2	1.0	85.0	66.0	29.0	0.0	26.6	0.351	31.0	tested...
3	8.0	183.0	64.0	0.0	0.0	23.3	0.672	32.0	tested...
4	1.0	89.0	66.0	23.0	94.0	28.1	0.167	21.0	tested...
5	0.0	137.0	40.0	35.0	168.0	43.1	2.288	33.0	tested...
6	5.0	116.0	74.0	0.0	0.0	25.6	0.201	30.0	tested...
7	3.0	78.0	50.0	32.0	88.0	31.0	0.248	26.0	tested...
8	10.0	115.0	0.0	0.0	0.0	35.3	0.134	29.0	tested...
9	2.0	197.0	70.0	45.0	543.0	30.5	0.158	53.0	tested...
10	8.0	125.0	96.0	0.0	0.0	0.0	0.232	54.0	tested...
11	4.0	110.0	92.0	0.0	0.0	37.6	0.191	30.0	tested...
12	10.0	168.0	74.0	0.0	0.0	38.0	0.537	34.0	tested...
13	10.0	139.0	80.0	0.0	0.0	27.1	1.441	57.0	tested...
14	1.0	189.0	60.0	23.0	846.0	30.1	0.398	59.0	tested...
15	5.0	166.0	72.0	19.0	175.0	25.8	0.587	51.0	tested...
16	7.0	100.0	0.0	0.0	0.0	30.0	0.484	32.0	tested...
17	0.0	118.0	84.0	47.0	230.0	45.8	0.551	31.0	tested...
18	7.0	107.0	74.0	0.0	0.0	29.6	0.254	31.0	tested...
19	1.0	103.0	30.0	38.0	83.0	43.3	0.183	33.0	tested...
20	1.0	115.0	70.0	30.0	96.0	34.6	0.529	32.0	tested...
21	3.0	126.0	88.0	41.0	235.0	39.3	0.704	27.0	tested...
22	8.0	99.0	84.0	0.0	0.0	35.4	0.388	50.0	tested...
23	7.0	196.0	90.0	0.0	0.0	39.8	0.451	41.0	tested...
24	9.0	119.0	80.0	35.0	0.0	29.0	0.263	29.0	tested...

Add instance Undo OK Cancel

• PASO 6:

Seleccionamos todos los datos que son imposibles que existan y los eliminamos:

Viewer


Relation: pima_diabetes

No.	1: preg	2: plas	3: pres	4: skin	5: insu	6: mass	7: pedi	8: age	9: class
	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Nominal
21	3.0	141.0	0.0	0.0	0.0	30.0	0.761	27.0	tested...
22	4.0	90.0	0.0	0.0	0.0	28.0	0.61	31.0	tested...
23	4.0	132.0	0.0	0.0	0.0	32.9	0.302	23.0	tested...
24	4.0	183.0	0.0	0.0	0.0	28.4	0.212	36.0	tested...
25	6.0	91.0	0.0	0.0	0.0	29.8	0.501	31.0	tested...
26	6.0	96.0	0.0	0.0	0.0	23.7	0.19	28.0	tested...
27	6.0	114.0	0.0	0.0	0.0	0.0	0.189	26.0	tested...
28	7.0	100.0	0.0	0.0	0.0	30.0	0.484	32.0	tested...
29	7.0	105.0	0.0	0.0	0.0	0.0	0.305	24.0	tested...
30	7.0	119.0	0.0	0.0	0.0	25.2	0.209	37.0	tested...
31	8.0	120.0	0.0	0.0	0.0	30.0	0.183	38.0	tested...
32	10.0	115.0	0.0	0.0	0.0	0.0	0.0	0.0	tested...
33	10.0	115.0	0.0	0.0	0.0	0.0	0.0	0.0	tested...
34	11.0	135.0	0.0	0.0	0.0	0.0	0.0	0.0	tested...
35	13.0	129.0	0.0	0.0	0.0	0.0	0.0	0.0	tested...
36	1.0	89.0	24.0	19.0	0.0	0.0	0.0	0.0	tested...
37	1.0	88.0	30.0	42.0	0.0	0.0	0.0	0.0	tested...
38	1.0	103.0	30.0	38.0	0.0	0.0	0.0	0.0	tested...
39	1.0	109.0	38.0	18.0	0.0	0.0	0.0	0.0	tested...
40	0.0	137.0	40.0	35.0	0.0	0.0	0.0	0.0	tested...
41	1.0	119.0	44.0	47.0	0.0	0.0	0.0	0.0	tested...
42	3.0	102.0	44.0	20.0	0.0	0.0	0.0	0.0	tested...
43	3.0	113.0	44.0	13.0	0.0	22.4	0.14	22.0	tested...
44	6.0	108.0	44.0	20.0	130.0	24.0	0.813	35.0	tested...

Undo
Copy
Search...
Clear search
Delete selected instance
Delete ALL selected instances
Insert new instance
Set instance weight

Add instance Undo OK Cancel

Se borraron 35 instancias por pres = 0 (Esto porque no existe persona que tenga presión 0)



Ahora seguiremos con skin:

Son 194 instancias que se deberían de borrar al igual que insu, pero para conservar el modelo del poder estadístico. (Lo mantendremos por ahora así)

Ahora en mass:

Viewer

Relation: pima_diabetes

No.	1: preg	2: plas	3: pres	4: skin	5: insu	6: mass	7: pedi	8: age	9: class
	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Nominal
1	5.0	136.0	82.0	0.0	0.0	0.0	0.64	69.0	tested...
2	8.0	125.0	96.0	0.0	0.0	0.0	0.232	54.0	tested...
3	0.0	118.0	64.0	23.0	89.0	0.0	1.731	21.0	tested...
4	0.0	102.0	75.0	23.0	0.0	0.0	0.572	21.0	tested...
5	1.0	83.0	68.0	0.0	0.0	18.2	0.624	27.0	tested...
6	1.0	97.0	70.0	15.0	0.0	18.2	0.147	21.0	tested...
7	1.0	97.0	64.0	19.0	82.0	18.2	0.299	21.0	tested...
8	0.0	104.0	76.0	0.0	0.0	18.4	0.582	27.0	tested...
9	1.0	80.0	55.0	0.0	0.0	19.1	0.258	21.0	tested...
10	3.0	99.0	80.0	11.0	64.0	19.3	0.284	30.0	tested...
11	1.0	103.0	80.0	11.0	82.0	19.4	0.491	22.0	tested...
12	1.0	100.0	74.0	12.0	46.0	19.5	0.149	28.0	tested...

Se eliminan 4 instancias.

Aahora en plas:

Viewer

Relation: pima_diabetes

No.	1: preg Numeric	2: plas Numeric	3: pres Numeric	4: skin Numeric	5: insu Numeric	6: mass Numeric	7: pedi Numeric	8: age Numeric	9: class Nominal
1	1.0	0.0	48.0	20.0	0.0	24.7	0.14	22.0	tested...
2	1.0	0.0	74.0	20.0	23.0	27.7	0.299	21.0	tested...
3	1.0	0.0	68.0	35.0	0.0	32.0	0.389	22.0	tested...
4	6.0	0.0	68.0	41.0	0.0	39.0	0.727	41.0	tested...
5	5.0	0.0	80.0	32.0	0.0	41.0	0.346	37.0	tested...
6	5.0	44.0	62.0	0.0	0.0	25.0	0.587	36.0	tested...
7	2.0	56.0	56.0	28.0	45.0	24.2	0.332	22.0	tested...
8	0.0	57.0	60.0	0.0	0.0	21.7	0.735	67.0	tested...
9	9.0	57.0	80.0	37.0	0.0	32.8	0.096	41.0	tested...
10	3.0	61.0	82.0	28.0	0.0	34.4	0.243	46.0	tested...
11	7.0	62.0	78.0	0.0	0.0	32.6	0.391	41.0	tested...
12	8.0	65.0	72.0	23.0	0.0	32.0	0.6	42.0	tested...
13	0.0	67.0	76.0	0.0	0.0	45.3	0.194	46.0	tested...
14	2.0	68.0	62.0	13.0	15.0	20.1	0.257	23.0	tested...
15	2.0	68.0	70.0	32.0	66.0	25.0	0.187	25.0	tested...
16	10.0	68.0	106.0	23.0	49.0	35.5	0.285	47.0	tested...

Se eliminan 5 instancias.

• Paso 7:

Después de haber filtrado algunos datos, pasaremos a generar el árbol J48: Dandonos como resultado lo siguiente:

```

=== Run information ===

Scheme:      weka.classifiers.trees.J48 -C 0.25 -M 2
Relation:    pima_diabetes
Instances:   724
Attributes:  9
              preg
              plas
              pres
              skin
              insu
              mass
              pedi
              age
              class
Test mode:   10-fold cross-validation

=== Classifier model (full training set) ===

```

J48 pruned tree

```
plas <= 143
|  mass <= 26.3: tested_negative (131.0/3.0)
|  mass > 26.3
|  |  age <= 28: tested_negative (210.0/34.0)
|  |  age > 28
|  |  |  plas <= 99: tested_negative (51.0/8.0)
|  |  |  plas > 99
|  |  |  |  pedi <= 0.527: tested_negative (107.0/44.0)
|  |  |  |  pedi > 0.527: tested_positive (54.0/15.0)
plas > 143: tested_positive (171.0/50.0)
```

Number of Leaves : 6

Size of the tree : 11

Time taken to build model: 0 seconds

Time taken to build model: 0 seconds

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	540	74.5856 %
Incorrectly Classified Instances	184	25.4144 %
Kappa statistic	0.4191	
Mean absolute error	0.3134	
Root mean squared error	0.4391	
Relative absolute error	69.4258 %	
Root relative squared error	92.4411 %	
Total Number of Instances	724	


=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.840	0.434	0.787	0.840	0.813	0.421	0.759	0.812	tested_negative
	0.566	0.160	0.650	0.566	0.605	0.421	0.759	0.587	tested_positive
Weighted Avg.	0.746	0.340	0.740	0.746	0.741	0.421	0.759	0.735	

=== Confusion Matrix ===

a	b	<-- classified as	
399	76		a = tested_negative
108	141		b = tested_positive

Nuevo árbol:



PASO 8: Ahora después de haber filtrado los datos y obtener el nuevo árbol tenemos el siguiente cuadro en el cual comparamos el antes y el después: (Se eliminaron 44 instancias en total)

Métrica	Antes (768 instancias)	Después (724 instancias)
Accuracy	73.83%	74.59%
Kappa	0.4164	0.4191
Tamaño del árbol	39 nodos, 20 hojas	11 nodos, 6 hojas
Falsos positivos	93	76
Recall (positivos)	0.597	0.566
RMSE	0.4463	0.4391

CONCLUSIONES:

- El filtrado manual de outliers no mejoró drásticamente el accuracy, pero sí generó un árbol mucho más simple e interpretable, reduciendo el sobreajuste a datos ruidosos, a costa de una leve pérdida de sensibilidad para detectar la clase positiva — posiblemente por la reducción en la cantidad de casos positivos disponibles tras el filtrado.
- También recordar que no se eliminaron las variables insu y skin porque son grandes cantidades que se eliminan y nos estaríamos quedando con pocos datos.
- Los resultados muestran que, si bien el accuracy mejoró levemente (de 73.83% a 74.59%), el cambio más significativo se dio en la **complejidad del árbol**: pasó de 39 nodos y 20 hojas a solo 11 nodos y 6 hojas. Esto indica que buena parte de la estructura del árbol original se dedicaba a "explicar" instancias ruidosas producto de datos faltantes mal codificados, y no a capturar patrones reales de la enfermedad. Al depurar esos registros, el modelo resultante es considerablemente más simple e interpretable, y se apoya en solo cuatro atributos clave (**plas, mass, age, pedi**), dejando fuera preg, pres, skin e insu por su bajo poder predictivo.